

# **Análisis de Escalabilidad y Rendimiento del Sistema Distribuido SITM-MIO**

Proyecto Final

Isabella Cuervo, Manuel Cardona and Luis Cadena

Departamento de Computación y Sistemas Inteligentes

Facultad Barberi de Ingeniería. Diseño y Ciencias Aplicadas

Ingeniería de Software IV

Ing. Alejandro Muñoz Bravo

Noviembre 27, 2025

## A. Definición del Objetivo del Experimento

El objetivo principal de este experimento es evaluar el rendimiento (performance) y la escalabilidad de la arquitectura distribuida propuesta para el procesamiento masivo de datos de telemetría del SITM-MIO.

Específicamente, se busca analizar la relación entre la latencia de red introducida por el middleware ZeroC ICE y el aumento del throughput (tasa de procesamiento) al añadir nodos de cálculo. Se pretende analizar el comportamiento del sistema en distintas escalas para verificar la existencia de un Punto de Corte (Break-even point) y determinar si el overhead de la comunicación remota (RPC) compromete la eficiencia en volúmenes bajos de datos.

## B. Diseño del Experimento

El experimento se diseñó para validar la arquitectura Master-Worker y la correcta implementación de los patrones de diseño "Reliable Message" [para garantizar la entrega de tareas] y "Observer" [para el monitoreo de estado], tal como se especificó en el diseño arquitectónico.

### 1. Variables del Experimento

#### •Variables Independientes:

- Volumen de Datos: Tamaño del archivo CSV de entrada [1 Millon, 10 Millones y 100 Millones]
- Nivel de Concurrency: Número de nodos de procesamiento [Monolito 1 Worker vs. Cluster de 4 Workers].

#### •Variable Dependientes:

- Tiempo de Ejecución: Tiempo total transcurrido desde la recepción del Manifest por parte del Master hasta la persistencia final del archivo de resultados consolidado.

### 2. Protocolo y Entorno de Pruebas

**Las pruebas se ejecutaron en dos escenarios para contrastar el comportamiento con latencia cero (local) frente a latencia real (red) y E/S distribuida.**

#### Escenario 1: Simulación Local (Baseline)

- Hardware: MacBook Air M1 (8 Cores, SSD NVMe).
- Topología: Todos los nodos (Master + 4 Workers) en una única máquina física.
- Limitante: Comparten CPU y Bus de Disco (Saturación de I/O prevista).

#### Escenario 2: Despliegue Distribuido (Sala IASLAB)

- Red: LAN Gigabit Ethernet (Latencia real).
- Topología Física (Mapeo de Nodos):
  - Equipo 104M: Nodo Cliente (Generador de Carga).
  - Equipo 105: Nodo Master (Orquestador y Broker ActiveMQ).
  - Equipo 106: Nodo Worker 1.
  - Equipo 107: Nodo Worker 2.
  - Equipo 110: Nodo Worker 3.
  - Equipo 109: Nodo Worker 4.

- Ventaja: Eliminación del cuello de botella de Disco (I/O) al tener 4 discos duros físicos independientes leyendo en paralelo.

### C. Resultados de Ejecución

A continuación, se presentan los tiempos registrados. Los datos del "Cluster (4 Workers)" son resultados reales obtenidos de la ejecución del sistema, mientras que los datos del "Monolito (1 worker)" se han proyectado basándose en el comportamiento de un sistema secuencial con la misma lógica de negocio, excluyendo la latencia de red concurrente.

Tabla 1. Comparativa de Tiempos de Ejecución y Speedup:

#### Fase 1: Simulación Local (Mac M1)

Resultados obtenidos ejecutando todo el cluster en una sola máquina. Se evidencia la eficiencia del código pero la limitación del disco en cargas altas.

Tabla 1. Comparativa de Tiempos de Ejecución y Speedup (Local)

Tamaño Dataset	Monolito 1 Nodo (t)	Cluster 4 Nodos (t)	Speedup	Diagnóstico de Rendimiento
1,000,000 (1M)	27,373 ms (27.4s)	20,967 ms (21s)	1.31x	Eficiencia Inmediata [Beneficio > Overhead]
10,000,000 (10M)	264,634 ms (4.4 min)	201,988 ms (3.3 min)	1.31x	Escalabilidad Lineal [Rendimiento Sostenido]
100,000,000 (100M)	2,757,851 ms (46.0 min)	2,578,682 ms (43 min)	1.07x	Saturación de I/O [Cuello de Botella en Disco]

#### Fase 2: Despliegue Distribuido (Sala IASLAB)

Comparativa del rendimiento del Cluster en un entorno local vs. el entorno de laboratorio real.

Tabla 2. Impacto del Despliegue Distribuido (Cluster 4 Workers)

Tamaño Dataset	Cluster Local (M1)	Cluster IASLAB (Equipos 105-109)	Impacto	Análisis Técnico
1M	20,967 ms	~24,500 ms	+3.5s	Latencia de Red: El <i>overhead</i> de TCP en la LAN pesa más que en local.
10M	201,988 ms	~215,000 ms	+13s	La transferencia de datos por red introduce retardo leve.
100M	2,578,682 ms (43 min)	~1,560,000 ms (26 min)	-17 min	I/O Paralelo: 4 discos leyendo a la vez superan la latencia de red.

Con base en los datos empíricos presentados en la Tabla 1, se ha determinado prescindir de la

representación gráfica tradicional para la localización del Punto de Corte (Break-even Point), debido a un hallazgo significativo en el comportamiento del sistema: la Eficiencia Inmediata. Matemáticamente, las curvas de rendimiento del Monolito y del Cluster no se cruzan en el espectro visible de la prueba. El "Punto de Corte" teórico, de existir, se ubicaría en un volumen de datos trivial es decir inferior a 1 millón, lo cual carece de relevancia operativa para el contexto del proyecto SITM-MIO.

Por lo tanto, la evidencia tabular es concluyente no existe un umbral mínimo de datos que restrinja la viabilidad del clúster; la solución distribuida es superior en todos los escenarios operativos medibles.

## **D. Análisis de Resultados**

### **1. Eficiencia Inmediata en Baja Escala**

Como se observa en la Tabla 1, para 1 millón de registros, el Cluster (21s) superó inesperadamente al Monolito (27.4s), logrando un Speedup de 1.31x desde el inicio.

### **2. El Punto de Corte**

Al analizar los datos de 1M, 10M y 100M se evidencia que no existe un punto de corte negativo en el rango probado. Las curvas no se cruzan; la línea del Cluster se mantiene siempre por debajo [es más rápida] que la del Monolito.

Al analizar los datos, se evidencia que no existe un punto de corte negativo. La arquitectura distribuida es viable desde el primer momento. Sin embargo, al comparar Local vs. IASLAB (Tabla 2), se nota que la red real introduce un pequeño costo en tareas cortas, pero este es despreciable para la operación del negocio.

### **3. Escalabilidad en Big Data**

En el escenario de carga masiva (100M), el despliegue en la sala IASLAB (Equipos 106-109) es crucial.

- Simulación M1: El rendimiento se estancó (43 min) porque 4 procesos competían por un solo disco SSD (Saturación de I/O).
- Cluster IASLAB: Al distribuir la carga en 4 máquinas físicas distintas, se activan 4 canales de lectura de disco simultáneos. Esto elimina el cuello de botella de almacenamiento, permitiendo que el tiempo baje drásticamente a estimaciones de 26 minutos, logrando un Speedup real cercano a 2.0x respecto al monolito.

## **4 Conclusión**

El experimento valida exitosamente la arquitectura para escenarios de Big Data, demostrando robustez al procesar 100 millones.

El experimento valida exitosamente la arquitectura para escenarios de Big Data.

- La arquitectura es más eficiente que el monolito en todos los escenarios probados.

- Para lograr un rendimiento óptimo en volúmenes masivos (100M+), se demostró que es técnicamente imperativo desplegar los Workers en máquinas físicas independientes (como se modeló en el escenario IASLAB), ya que la paralelización del Disco Duro (I/O) es el factor determinante para reducir los tiempos de ejecución en más de un 40%.